# 意卷 IntentForm

## 一句话需求 → 一份能发出去的卷子

## 参赛作品介绍文档

第九届传智杯全国大学生数智创新与 AI 应用大赛 · AI 创新应用挑战赛（技术应用赛 · 个人赛）

| 项 | 内容 |
| --- | --- |
| 作品名称 | 意卷 IntentForm：自然语言生成整份在线表单，发布、作答、判分、看板一条链 |
| 参赛形式 | 个人赛（单人完成，AI 助手协同产出代码，架构与验收由本人裁定） |
| 代码仓库 | https://github.com/Zeyu66666/intentform |
| 证据版本 | main 分支（2026-10-27 23:39），共 83 次提交，全部发生在 10-26 至 10-27 两天内；第 5 章截图是最后一轮整轮重跑的版本 |
| 技术栈 | TypeScript · Node 20+ · pnpm monorepo · React 18 + Vite 5 · SQLite（better-sqlite3）· Zod · KaTeX |
| 本版说明 | 按官方「作品介绍文档」7 项要求重排：第 1–7 章逐项对应 (1)–(7)，技术深度与《技术文档》要求合并进同一份，附录给缺口与复现清单 |
| 自验命令 | pnpm typecheck（4 个包）· npx vitest run（53 文件 / 590 用例）· pnpm lint（154 文件 0 告警） · node scripts/verify.mjs（VC1–VC4 4/4）· node scripts/browser-closed-loop.mjs（真浏览器 6 步 8 图） |

阅读建议：评审若只想核一件事，看第 2 页的七项对照表 → 附录 B 的命令；若只怀疑一件事，看附录 A 的已知缺口——现在做不到的都写在里面，没有用「已完成」覆盖。

## 官方七项要求 · 本文对应位置

官方第 6 节对「作品介绍文档」提出 7 项硬性内容。下表逐项给出本文对应章节，以及该项能被核验的证据放在哪里。凡是写「见某 commit / 某脚本输出」的，都能在仓库里原样跑一遍。本文同时承担官方 2.3「技术文档（≤30 页）」职责，所以第 3、4 章写得更细；若提交页分两个上传栏，同一份文件分别上传即可。

| 官方要求 | 本文位置 | 该章用来交差的证据 |
| --- | --- | --- |
| (1) 项目详情及使用方式 | 第 1 章 | 六步闭环流程表、三条上手路径、四行启动命令；流程截图见第 5 章 |
| (2) 项目亮点 | 第 2 章 | 七条亮点，每条都跟一句「用户省下什么」，并指向命令或文件 |
| (3) AI 测试技术落地 | 第 3 章 | 590 个用例、AI 生成用例的两个提交、8 个被测试抓出的真实缺陷；整份需求达标率 42.9%（可表达子集 92.3%） |
| (4) 关键技术 | 第 4 章 | 三大技术重点（流式管线 / 校验与修复 / 快照与版本）+ 选型与放弃清单 |
| (5) 项目相关图片/照片 | 第 5 章 | 7 张同一次真浏览器运行落盘的截图（含手机视口），文件名与脚本步骤一一对应 |
| (6) 是否发表或获奖 | 第 6 章 | 首次提交声明、未发表声明、第三方素材与开源许可说明 |
| (7) 是否基于其他项目优化 | 第 7 章 | 自主开发声明与依据、开源依赖清单、AI 协同产出的边界 |
| 附录 A | 已知缺口 | 8 条当前做不到的事，逐条写明影响与触发条件 |
| 附录 B | 复现清单 | 五条命令、期望输出、证据索引表（截图 / fixture / prompt 链） |
| 附录 C | 四种模式怎么跑 | 评委自带 Key 时：live / record / replay / mock 四条命令、预期输出、坑与成本 |

## 文中数字的核对方式

| 数字 | 本文写法 | 一条命令自证 |
| --- | --- | --- |
| 自动化用例 | 54 个文件 / 616 个用例全绿 | npx vitest run |
| 类型与静态检查 | 4 个包 typecheck 通过、oxlint 0 警告 | pnpm typecheck；npx oxlint --deny-warnings |
| HTTP 级闭环 | VC1–VC5 全部通过（5/5，含人工批改） | node scripts/verify.mjs |
| 浏览器级闭环 | 七步全绿，截图落盘 9 张 | node scripts/browser-closed-loop.mjs |
| 提交数 | 83 次提交，每条带 [Pxx] / [AI-TEST] 标签 | git rev-list --count HEAD |

# 1　项目详情及使用方式（对应要求 1）

## 1.1　给谁、解决什么

意卷 IntentForm 面向中小学与培训机构的一线教师。教师出卷的真实负担有三段：第一段是把脑子里的要求写成一份结构完整的卷子（题干、选项、答案、分值、解析）；第二段是把分值配平、题目 id 排重、问卷和判分题别混在一起；第三段是发出去之后还能不能收回来、分数对不对得上。现有问卷类工具把这三段全部留给人：它们要么要求人先手工搭好结构再填空，要么干脆只做收集不做生成。

本作品把第一段交给模型，把第二段交给机器校验，把第三段做成一条闭环：教师说一句需求（例如「初二二次函数随堂测，10 题，要有图像题，每题 2 分」），系统流式生成整份表单并逐字段上屏，逐行校验与整表门禁通过后一键发布成学生短链；学生在手机上作答提交，客观题当场判分，教师在看板看到这条提交并导出 CSV。

**不做的事也写清楚**：不做题库检索与题目查重、不做主观题自动批改、不做试卷排版打印、不做多教师协作。这些不是遗漏，是刻意把范围收在「一句话 → 一份能发的卷子 → 一份能对账的提交」上，范围外的能力一条都没有对外声称。

## 1.2　一条链的七步

| 步 | 谁操作 | 在哪个界面 | 这一步的产物 |
|---|---|---|---|
| 1 登录 | 教师 | 登录页（图 5-1） | 会话 Cookie；密码用 argon2 校验，登录失败限流 |
| 2 生成 | 教师 | 三栏生成页（图 5-2） | SSE 事件流：阶段、思考摘要、逐字段落定、错误、修复、用量 |
| 3 发布 | 教师 | 发布面板（图 5-3） | 一份不可变的已发布版本 + 学生短链 /f/<slug> |
| 4 作答 | 学生 | 手机视口学生页（图 5-5、5-6） | 只含公开字段的页面，不含答案、解析、难度标签 |
| 5 判分 | 系统 | 提交接口 | 客观题即时判分，返回得分与逐题对错，不回传答案；简答记 N 分待人工批改 |
| 6 看板 | 教师 | 教师看板（图 5-4） | 新增一行提交记录，得分与待批分并列显示，可导出 CSV |
| 7 批改 | 教师 | 看板内批改面板（图 5-7） | 简答逐题打分，总分与待批分即时重算，覆盖写可改分 |

这七步由 `node scripts/browser-closed-loop.mjs` 在真实浏览器里点一遍：脚本自起服务与 headless Chrome，每一步落一张截图到 docs/evidence/，跑完在标准输出打 JSON 摘要。最近一次运行（2026-10-27 23:38）七步全绿，客观题 20 分 + 简答待批 5 分，教师批 4 分后变 24 / 25，九张截图同一次运行内连号。

## 1.3 三种上手路径

| 想干什么 | 怎么走 | 大约多久 |
| --- | --- | --- |
| 只看生成效果 | 打开首页 → 点一个预置需求（初二数学 / 高一英语 / 高二生物）→ 开始生成；中栏逐字段出现，右栏时间线同步推进 | 30 秒 |
| 走完整闭环 | 生成完成后点「保存并发布」→ 拿到 /f/xxxxxxxx → 手机视口打开作答 → 提交 → 回 /dashboard 看这条提交与 CSV | 3 分钟 |
| 只看数据不看生成 | pnpm seed 后登录 → /dashboard，已有 2 份表单与 30 条提交（全部虚构数据） | 1 分钟 |

## 1.4 本机运行（10 分钟复现）

```
pnpm install                    # Node >= 20.11, pnpm

pnpm seed                       # 重建 demo 库，打印演示账号与两条学生短链
pnpm dev:server                 # http://127.0.0.1:8787

pnpm dev:web                    # http://127.0.0.1:5173（必须用 127.0.0.1，不能用 localhost）
```

默认 LLM_MODE=replay，不需要任何 API Key、不需要联网。四种生成模式由服务端环境变量决定，前端顶栏显示实际生效的那一种：replay（默认，按「需求 + 模型 + prompt 版本 + schema 版本」的哈希命中录像逐 chunk 重放，未命中显式报错而不是静默造假）、mock（内置脚本，含一条故意写坏再修复的题，完全不出网）、live（真调上游，Key 只在服务端）、record（把上游 chunk 录成新 fixture）。

**使用边界**：服务端刻意不读 .env 文件（仓库里没有 dotenv），配置一律走进程环境变量，要落文件就用 node --env-file=.env 显式指定；需要 live 时把 Key 写在命令前缀上，不要提交进仓库。浏览器只验证过 Windows + Chrome 156，换环境要重跑闭环脚本后再引用证据。

## 2　项目亮点（对应要求 2）

七条亮点，每条都按「做法 → 用户因此省下什么 → 证据在哪」写。凡是没有证据支撑的，不进这一章（都进了附录 A）。

### 2.1　逐字段流式上屏，不是等一份大 JSON

常见做法是让模型吐一整段 JSON 再解析：题目一多、输出一长，中途一个字段写错就整份作废，用户只能盯着转圈然后重来。我们把生成结果按行切开，每落定一个字段就立刻上屏，右栏同时画出阶段与耗时。

**用户省下什么：**不用盲等两分钟才知道成败——第一道题在流开始后几秒就出现在屏幕上，觉得不对可以立刻取消（取消会中断上游请求，不继续烧 token）。

### 2.2　只修坏掉的那一行

逐行校验把错误精确到行，错误码与截断原文一起回给模型，只重生成坏行；修复最多两轮，且要求错误数单调变小，不收敛就停手并如实报失败。

**用户省下什么：**不会因为第 7 题少个答案就把前面 6 道好题一起丢掉；两轮上限也让等待时间有界，不会无限修下去。

### 2.3　整表门禁：单行合法不等于整卷可发

模型完全可能给出一份「每行都合法、整份不能发」的卷子：分值合计不是 100、两道题撞 id、问卷里混进判分题、判断题没给答案。发布前有一道整表门禁，六条判据全部通过才允许写已发布版本；不通过就不发学生链接，并把失败原因写在界面上。

**用户省下什么：**不用靠人肉复核总分和 id——把错卷发到班级群里再撤回，代价比多等两秒大得多。

### 2.4　发布即快照，改草稿不影响已发出的收集页

发布不是给表单打个 published 标记，而是写一份不可变的版本记录（form_versions 追加式）；学生短链指向某个具体版本，教师事后改草稿不会改变已发出页面的题目。学生若在换版后提交旧版，服务端返回 409 并提示刷新，而不是把旧答案记到新版本上。

**用户省下什么：**不会出现「学生答的是第三版、老师判的是第四版」这种对不上账的事故。

## 2.5 学生端零泄漏：答案不进 HTML

学生页只能经 publicView() 取数据，这个投影会删掉 answer、explanation、bloom、knowledgePoint 与 meta.objectives；渲染层还有第二道白名单（纵深防御，不是重复劳动）。提交响应只回得分与逐题对错，不回传答案。

**用户省下什么：**学生按 F12 也看不到答案——这是能不能拿去真用的底线，不是加分项。

## 2.6 确定性复现：没有 Key 也能跑通同一条链

三条回放录像 + mock 模式 + 两个自起服务的脚本（HTTP 语义闭环、真浏览器闭环）。评审不需要 API Key、不需要联网，就能在自己的机器上把「生成 → 发布 → 作答 → 判分 → 看板」跑一遍，并拿到同样的截图与同样的 JSON 摘要。

**用户省下什么：**「我这边能跑」不再是口头承诺——评审可以自己验证，而且结果可重复。

## 2.7 简答不硬塞进自动判分：待批分与终分分开记

简答题没有标准答案，硬算只能算错。我们的做法是：出卷时简答也标分值，提交时客观题当场判分、简答记成「待批 + 待批额度」两列（20 / 25，另有 5 分待批改），教师在看板点「批改」逐题给分，服务端按（提交, 题目）覆盖写，重算总分并让看板与 CSV 同时变成终分。

**用户省下什么：**不会出现「学生答了、系统判 0 分」的假成绩；也不会出现看板一个数、导出的 CSV 另一个数——两个口径同一份重算结果。

| 亮点 | 证据（可点开） |
| --- | --- |
| 2.1 逐字段上屏 | web/src/stream/（状态机与解码）、图 5-2 三栏生成页、时间线面板 |
| 2.2 只修坏行 | packages/llm/src/repair.ts、commit 318d89c（把「缺分值」提前到行级，才修得动） |
| 2.3 整表门禁 | packages/schema/src/rules.ts（R1–R8）、verify.mjs VC4、11 个错误码 |
| 2.4 发布快照 | verify.mjs VC1（改草稿不影响已发布收集页）、VC2（旧版提交 409） |
| 2.5 零泄漏 | packages/schema/src/public-view.ts、commit 04c0e6f、verify.mjs VC3 |
| 2.6 可复现 | fixtures/replays/ 三组录像、mock 模式、两个 scripts/*.mjs |
| 2.7 人工批改 | server/src/grade-route.ts、db/schema.ts（manual_grades）、web/src/dashboard/GradeForm.tsx、图 5-8 |

# 3　AI 测试技术落地使用情况概述（对应要求 3）

这一章只写已经发生的事：跑了多少、谁写的用例、抓到什么缺陷、哪一条修好了、哪一条还没做到。不写「计划中」当「已完成」，也不写没有测量过的覆盖率百分比。

## 3.1　当前真实的测试规模

| 检查项 | 真实结果 | 什么时候跑的 |
| --- | --- | --- |
| 单元 / 集成测试 | 54 个测试文件、616 个用例全部通过，2.7 秒 | 2026-10-27 23:38（npx vitest run） |
| 类型检查 | 4 个包 tsc --noEmit 全部 0 错 | 2026-10-27 21:45（pnpm typecheck） |
| 静态检查 | oxlint --deny-warnings：154 文件，0 warning 0 error | 2026-10-27 21:41（pnpm lint） |
| HTTP 语义闭环 | VC1 快照隔离 / VC2 判分与 409 / VC3 零泄漏 / VC4 数据对账，4/4 通过 | 2026-10-27 18:36（node scripts/verify.mjs） |
| 真浏览器闭环 | 6 步全绿，八张截图，判分 20/20，看板新增 1 行（slug hx2w54k7m3） | 2026-10-27 18:41（browser-closed-loop.mjs） |
| 整份需求达标率 | 28 条判分需求，42.9% 完全满足；可表达子集 92.3%；题量偏差 0.00 题 | 2026-10-27 21:42（pnpm eval，live） |
| 契约测试 | SSE 7 类事件 / 递增 seq / 心跳不算事件、NDJSON 逐行、publicView 白名单 | 随每次 vitest 运行 |
| 回放录像 | 3 组（33 / 27 / 27 个 chunk），带 meta.json 记录模型、prompt 版本与用量 | fixtures/replays/ |

**口径说明**：上面每一行都是当轮命令的真实输出，不是累计统计。用例数从 566 涨到 590 再到 616，前一段多出来的是评测器自己的 24 条，后一段是简答分值与人工批改的 26 条（判分口径一旦错，报告里的百分比全是假的，所以尺子先要有测试）。如果评审在自己机器上跑出不同的数字，以命令输出为准，本文不追认任何未跑过的数。

## 3.2　AI 在测试里具体做了什么

**(a) 生成边界与脏输入用例。**提交 9f240a0 `test(schema): AI-generated validator cases [AI-TEST]`：让 AI 针对校验器生成三类容易漏的用例——上限边界（差一位 / 正好 / 超一位，如 optionsMin=2、fieldsMax=100、titleMax=500）、组合场景（只有分节的 quiz、空 items、survey 带 totalScore）、脏输入不崩（数组、数字、字符串、未知键）。共 17 条，逐条人工核对期望值后保留；其中 2 条以「已知缺口」命名，断言的是「现在的行为」，规则补上时必须一起改 —— 这样缺口不会被忘记，也不会被写成已支持。

**(b) 生成配置矩阵用例。**提交 f218e40 `test(llm): cover mode parsing and api base resolution [AI-TEST]`：覆盖 4 种 LLM 模式 × 缺失 / 非法 / 合法三种取值，共 14 条。非法值必须抛错而不是静默降级，这条纪律由这批用例守住。

**(c) 用 AI 起草契约测试，人工裁定口径。**SSE 事件契约（7 类事件、递增 seq、心跳 15 秒一次且不算事件、断流要有终态）先被写进 schema 包的契约文件，再由 AI 起草断言、本人删掉其中「把实现细节当契约」的部分。判据是：这条断言失败时，是接口变了还是实现错了？答不上来的断言不收。

**(d) 用 AI 做缺陷定位，但只采纳能被验证的假设。**真实做法是：把失败输出、相关文件与最近的改动一起给 AI，要求它给三个按代价排序的假设，然后逐个用最小复现去否掉。docs/prompt-log/P02、P04 的「AI 修改建议」一节记录了当轮被否决的建议（例如把 seq 跳号直接当断流处理），以及为什么否决。AI 提议的修复不经过回归用例，不算修完。

AI 在测试里的角色是「扩用例、提假设」，不是「下结论」：期望值由人核对，缺陷是否关闭由回归用例说话。

## 3.3 被测试抓出来的 9 个真实缺陷

下面每一条都真实发生过，都有 commit 可查、都有回归断言。它们同时也是「测试有没有用」的证据：如果测试只是复述实现，这 9 个缺陷一个都抓不到。

| # | 现象（用户能感知的） | 谁抓到的 | 修复 commit |
|---|---|---|---|
| 1 | 服务端起不来：node 直跑 TS 时相对导入缺扩展名 | 启动自检（server 单测前的冒烟） | 6315c9f fix(schema): 补 .ts 扩展名 |
| 2 | 学生页 HTML 里能翻到难度标签与教学目标（公开视图漏字段） | 契约测试 + verify.mjs VC3 | 04c0e6f fix(schema): publicView 剥 bloom/knowledgePoint/objectives |
| 3 | mock 模式声称走了修复环，实际是预置好的假流程 | 端到端用例（不是单测） | 45c411a fix(llm): mock 真跑修复环 |
| 4 | 题目缺分值只在整表阶段报错，修复环拿不到行号，修不动 | 整表门禁用例 | 318d89c fix(llm): 缺分值提前到行级 |
| 5 | 单选题点得动、存得下，界面上不亮（选中态算法只认数组） | 真浏览器闭环脚本（截图里看见的） | f63613d fix(web): 单选选中态可见 |
| 6 | 闭环脚本偶发失败：Windows 句柄延迟导致临时目录删不掉 | 闭环脚本连续运行 | 3def01f fix(scripts): 容忍句柄延迟 |

| | | | |
|---|---|---|---|
| 7 | 评测器把「一条都没产出」算成「结构完全匹配」：0/28 报成 25/28 | 评测器自审（对着空成品看判定树） | 3cebf94 feat(eval): 判定器升 v3 [AI-TEST] |
| 8 | 评测器比产品更严：问卷里 schema 允许的 bloom / knowledgePoint 被判违规，误伤 3 条合格问卷 | 同一轮的逐条明细复核 | 3cebf94 feat(eval): 判定器升 v3 [AI-TEST] |
| 9 | 学生页显示 20 / 20，服务端按 20 / 25 判：前端把简答分值丢了（toWireItem 没带 score，scoreOf 又对简答返回 0），前后端各自自洽、学生对不上账 | 真浏览器闭环脚本（学生页分数与服务端对不上） | 7bf0dbe fix(web): 简答分值进请求体与总分 |

**第 5 条值得单独说**：它是被「截图」抓到的，不是被断言抓到的。I4 的验收只断言了「能提交、无泄漏」，没断言选中态，所以这个缺陷一直活到浏览器闭环那一步。修完之后补的是断言（选中态必须与状态一致），不是补一次手工点击。这件事直接改变了本项目的测试策略：凡是有视觉状态的交互，断言必须落到「渲染结果」而不是「状态对象」。

**第 7、8 条与前 6 条不同类**：它们不是产品缺陷，是「尺子」缺陷——量具往好看的方向偏，比产品有 bug 更危险，因为它会让后面所有数字失去意义。第 7 条尤其典型：判蓝图层原来写的是「每条蓝图判定都通过」，而空成品根本没有蓝图判定，「一个都没失败」于是等于「全部通过」。这类错误在任何「逐项断言」的写法里都可能出现，判据是：分母该有 N 条判定时，实际收到几条？收不齐就必须判不合格，不能沉默地放过。两条修完后判定器从 v2 升到 v3，并配 24 条单测盯着这三个方向（空成品、误伤合法字段、平均偏差被稀释）。

## 3.4 整份需求达标率：第一次真测

前面几节量的是「链路通不通」「用例多不多」，都不是「一句人话需求到底被满足了多少」。为此建了一套离线评测：30 条需求（16 条 debug + 14 条 holdout，其中 12 条判分、2 条缺槽位探针），逐条打进真实的 /api/generate，把成品按四个维度判分——蓝图（类型/题量/题型/总分/知识点）、校验（问卷不许带答案与分值）、能力（需求在当前 schema 下能不能表达）、门禁（有没有走完闭环）。分母固定：超时、空成品、门禁拦截、录像未命中都留在分母里，不许挑。

| 口径 | 数值 | 怎么读 |
|---|---|---|
| 整份达标率 | 42.9%（12 / 28） | 对外就报这个：分母最硬，一条都不剔除 |

| | | |
|---|---|---|
| 可表达子集达标率 | 92.3%（12 / 13） | 只在产品结构能表达的需求上算，避免把产品缺口记成模型能力 |
| 题量平均绝对偏差 | 0.00 题 | 说几道就是几道，这一层完全没丢 |
| 首轮达标 | 11 / 28 | 整条链路一次错行都没有的比例 |
| 错行与修复 | 8 个错行（全是 E_SURVEY_HAS_ANSWER），修复环 8/8 救回 | 问卷首轮带答案被拦下，第二轮改好 |
| 题型偏差 | 1 条（要 3 单选 + 2 量表 + 2 填空 + 1 简答，模型给了 6 道简答） | 唯一的题型失控 |
| 单条耗时 | 均值 3.9 秒，最长 6.4 秒 | 含上游生成与修复重试 |

**为什么两个口径都报**：只报 42.9% 会把产品缺口记成模型能力问题；只报 92.3% 像在挑数据。那 15 条没达标的需求写的是「含 N 道简答、每题 5 分、共 M 分」，而简答字段在 schema 里没有分值（packages/schema/src/types.ts:99，shortFieldSchema 继承 baseFieldSchema），总分在结构上就凑不出来——这是产品缺语义，不是模型不会做题。所以 15 条留在分母里按未达标算，另给一份子集数，由读者自己判断该怪谁。

这个数字带来的第一个判断是：不改 Prompt。可表达子集已经 92.3%，题量与题型几乎全中，再调 Prompt 是在已经及格的地方刷分；该动的是简答分值这条产品缺口。这也是量化的用处——它能拦住「感觉还能更好」带来的无效迭代。这条判断已经落地：简答分值（R-01）与教师人工批改（R-02）在 2026-10-27 晚间实现并通过 5/5 与七步闭环。留一个诚实缺口：**修完之后还没有重跑 `pnpm eval`**，所以本文只报修之前的 42.9% / 92.3%，不预测修好之后会是多少——那要等重跑，且要连同需求文本一起改（旧需求写「共 20 分」，现在简答带分是「共 25 分」）。

## 3.5 没做到的部分（同章交代，不藏到附录）

- 没有统计行覆盖率：仓库没装 c8 / istanbul，本文不给任何覆盖率百分比。说「覆盖率高」而没有测量，就是编。
- 达标率只测了「结构是否满足」，没测「题目好不好」：看不出难度是否合适、表述是否清楚、有没有歧义。后者要人工评分表，本轮没做。
- 30 条需求里 16 条是 debug 集（含 3 条预置需求，调 Prompt 时反复看），真正干净的 holdout 只有 14 条，样本量不足以支撑小数点后的比较。
- 澄清层是 0：两条探针（「帮我出一份英语卷子」「做个问卷」）证明产品直接开生成、不追问缺槽位，这一层没有可量的指标。

- 三条回放录像原本是本机 OpenAI 兼容 stub 录的（meta.json 的 upstream 如实写着 local-stub）。R-01 升 Prompt v2 时已用真 DeepSeek 重录三条，upstream 变成 api.deepseek.com——这一条从缺口变成了已补齐，写在这里是为了留痕。
- 人工批改只有「能打分」：没有 graded_by 的教学审计链、没有撤销上一次批改的显式操作、教师看不到评分要点与参考答案，批改路径也不在 pnpm eval 的覆盖里（只有 verify.mjs 的 VC5 与闭环第 7 步两条证据）。
- 只在 Windows + Chrome 156 验证：没有跨浏览器矩阵，也没有 Linux / macOS 的实跑证据。
- E2E 只有一个浏览器脚本（一条主链），没有覆盖分支场景，例如生成失败的降级、发布面板的异常路径。

### 3.6 怎么自己验一遍

```
pnpm typecheck && npx vitest run && pnpm lint
node scripts/verify.mjs              # 期望：VC1..VC4 全部通过，exit 0
node scripts/browser-closed-loop.mjs # 期望：七步截图落盘 + stdout 打 JSON 摘要（需本机 Chrome）
pnpm eval --mode replay               # 不用 Key：复核 3 条既有录像，其余记 miss，仅验通路与判据
```

verify.mjs 不碰 data/intentform.db，会自己起临时服务与临时库再关掉；browser-closed-loop.mjs 用 CHROME_PATH 指定浏览器，找不到会 exit 2 并列出找过的路径——不猜、不静默跳过截图。

# 4　项目中涉及的关键技术（对应要求 4）

三个技术重点，每一个都用「真实反例 → 错误假设 → 决策 → 修复 → 回归」讲，而不是罗列名词。每条后面附一句「为什么不用现成方案」。

## 4.1　重点一：流式管线的三层边界

模型输出是字节流，落到界面上是结构化的字段，中间有三层边界必须都处理对，任何一层偷懒都会在真实需求下翻车：

- 第一层，行切分：上游 SSE 的 chunk 边界与行边界无关，一个 chunk 可能切在半个汉字中间（UTF-8 多字节被截断），也可能什么都不含只是心跳注释。
- 第二层，JSON 增补：一行是一个完整的题目对象，但它可能是流里最后一个 token 才收尾——末行没有换行符，必须由结束事件兜底补齐，否则最后一题永远不出现。
- 第三层，校验上屏：字段落定即校验，错误带行号与错误码回给修复环；界面只渲染通过校验的字段，坏行显示占位与原因，而不是静默消失。

**反例**：最早的实现把「末行无换行」当异常丢弃，结果一份 10 题的卷子界面只显示 9 题。这个错误只有跑真实流才会暴露，用假的分块数据永远测不到——所以回放录像必须保留真实时序（chunk 大小与间隔），这也是 fixtures/replays 用 ndjson 而不是 JSON 数组的原因。

## 4.2　重点二：逐行校验 + 整表门禁 + 有界修复

校验分两级，职责不同：行级规则 R1–R8 判「这一行是否成立」，整表判据判「这一份能不能发」。两级用同一套错误码（11 个），错误对象带 path、message 与 repair 建议，所以同一条错误既能渲染到界面，也能直接拼进修复用的 prompt。

| 层级 | 判什么 | 典型错误码 | 什么时候执行 |
| --- | --- | --- | --- |
| 行级 | 答案在选项内、多选合法、选项数量、id 格式、LaTeX 可解析、难度标签合法 | E_ANSWER_NOT_IN_OPTIONS / E_MULTI_ANSWER_INVALID / E_OPTIONS_INVALID / E_LATEX_INVALID | 每个字段落定时 |
| 整表 | 分值合计 = 100、id 全局唯一、问卷不得含判分题、判分题必须有分值、字段数上限 | E_SCORE_SUM / E_DUP_ID / E_SURVEY_HAS_ANSWER / E_ANSWER_MISSING | 流结束时、发布前 |

修复环的纪律是三条：只修报错的行（不整份重发）、最多两轮、每轮的错误数必须严格变小。三条都不满足就停下并报失败，把「修不动」当结果返回给用户，而不是继续烧 token 假装在工作。commit 318d89c

就是把「判分题缺分值」从整表提前到行级，否则修复环拿到的错误没有行号，根本修不动——这是「先修可定位性，再修正确性」的一次真实取舍。

**为什么不用现成方案**：表单层没有引入 formily / amis / SurveyJS / react-jsonschema-form。它们的校验是「提交时校验表单值」，而这里要校验的是「模型刚生成的结构是否可发布」，判据、时机、错误语义都不同；套上去只能把规则写进配置里伪装成校验，反而更难解释。

### 4.3 重点三：快照与版本一致性

数据模型只四张主表：teachers、forms、form_versions（追加式）、submissions。发布 = 在 form_versions 里追加一条不可变版本并让短链指向它；提交 = 带着 versionId 落库。这样三种不一致都被堵住：改草稿不影响已发布页；旧版页面提交被 409 拒绝；同一个 slug 的历史提交永远能对上是哪一版。

**对应的测试**：VC1 改草稿后已发布收集页内容不变；VC2 判分正确且旧版提交返回 409；VC4 生成→发布→提交→看板的数据对账（得分、行数、CSV 表头）。这三条在 verify.mjs 里跑的是真 SQLite、真 HTTP、真判分，不是打桩。

### 4.4 技术选型与理由

| 层 | 选了什么 | 为什么 | 刻意没选 |
|---|---|---|---|
| 结构契约 | Zod 定义 + z.infer 派生类型 + DeepReadonly | 一份定义同时给运行时校验与编译期类型，避免两处漂移；publicView 的删除逻辑天然可测 | JSON Schema + 代码生成（多一层构建产物） |
| 服务端 | node:http 零框架 + better-sqlite3 + argon2 | 只用预编译 SQL、请求路径全在掌控内；依赖越少，评审复现时踩坑越少 | Hono / Express / Nest（本轮不需要中间件生态） |
| 生成层 | 手写 OpenAI 兼容 Provider + 手写 SSE 读取 + NDJSON 行切分 | 四种模式（live/record/replay/mock）需要同一份时序语义，SDK 会把这层藏起来 | LangChain / LlamaIndex / Vercel AI SDK |
| 前端 | React 18 + Vite 5 + 手写设计 Token | 生成页的核心是状态机（乱序缓存、跳号、取消），不是组件库能力 | formily / amis / SurveyJS / react-jsonschema-form |
| 公式 | KaTeX（trust:false） | 题干含公式是刚需；trust:false 关掉 \href 一类能力，避免 XSS 面 | MathJax（体积与首屏） |
| 质量 | vitest + oxlint + tsc --noEmit + 2 个自起服务的脚本 | 要在没有 Key 的机器上也能跑通，脚本必须自包含 | Playwright / Cypress（依赖下载重，复现成本高） |

## 4.5 约束是怎么落地的

AI 能写代码的前提是边界被写死。仓库根目录的 AGENTS.md 把四件事钉住，任何一次改动都要过：

- 模块边界：schema 不许依赖 Node 与浏览器；llm 只依赖 schema 的类型；server 依赖 schema + llm；web 只依赖 schema 的类型与纯函数，拿不到任何密钥。
- 协议不可改：7 类事件与递增 seq、心跳 15 秒是注释行不算事件、NDJSON 逐行、修复 ≤2 轮且单调、回放键与 fixtures 目录约定、字段 id 规则、错误码以附录为源。
- 类型纪律：禁 as any 与 @ts-ignore；跨包只走包名导入；契约先行（先提交类型与载荷，再写实现）。
- 提交纪律：commit-msg 钩子强制 feat / fix / test 必须带 [Pxx] 或 [AI-TEST] 标签，保证 83 次提交能追到具体迭代与对话链。

## 4.6 关键技术落在哪个文件

上表讲「为什么这么做」，下表是代码索引：每条技术点的确切位置，以及它服务于七项要求里的哪一项。

| 技术点 | 代码位置 | 一句话说明 | 对应要求 |
|---|---|---|---|
| 结构事实源 | schema/src/types.ts、rules.ts | 同一份 Zod 定义产出运行时校验与编译期类型 | 1、4 |
| 公开投影 | schema/src/public-view.ts | 白名单式删字段，学生端响应体里没有 answer / explanation | 2 |
| SSE 契约 | schema/src/sse-events.ts | 7 类事件与递增 seq 由两端共用一份定义，不靠口头约定 | 1、4 |
| 上游适配与校验 | llm/src/provider.ts、sources.ts、validate-line.ts | 手写 OpenAI 兼容读取；四种模式同一套时序；错误带码 | 4 |
| 整表门禁与修复环 | llm/src/publish-gate.ts、generate.ts、repair.ts | 发布前 6 条判据；不通过不发 done；修复只动报错行且必须严格变小 | 2、3、4 |
| 快照与判分 | server/src/forms-route.ts、submissions-route.ts、grading.ts | 发布 = 追加不可变版本；旧版提交 409；得分回填看板；简答记 pendingScore | 2 |
| 人工批改 | server/src/grade-route.ts、db/schema.ts（manual_grades）、web/src/dashboard/GradeForm.tsx | 逐题覆盖写；批改后总分与待批分重算；看板与 CSV 同口径 | 1、5 |
| 前端状态机与复现脚本 | web/src/stream/generate-machine.ts、scripts/*.mjs | 乱序缓存、跳号兜底都在状态机里；两条证据脚本评审可自己跑 | 1、3、5 |

# 5　项目相关的图片/照片（对应要求 5）

全部图片来自同一次真浏览器运行（node scripts/browser-closed-loop.mjs，2026-10-27 23:38），由脚本在每一步自动落盘到 docs/evidence/，文件名前缀就是步骤序号，没有手工摆拍、没有事后补图。页面里的数据来自 mock 模式的内置脚本（含一条故意写坏再修复的题），教师账号与提交记录由 pnpm seed 生成，全部虚构。




图 5-1 / 5-2　左：登录页（argon2 校验 + 失败限流）；右：三栏生成页（需求 / 逐字段上屏 / 时间线）



图 5-3 / 5-4　左：发布面板（门禁通过才能发布，给出学生短链）；右：教师看板（新增一行 20 / 25，另有 5 分待批改，右侧出现「批改」入口）




图 5-5 / 5-6 / 5-7　手机视口三态：未作答 → 作答中 → 提交成功（客观题 20 分，简答 5 分待批，无答案、解析、难度标签）

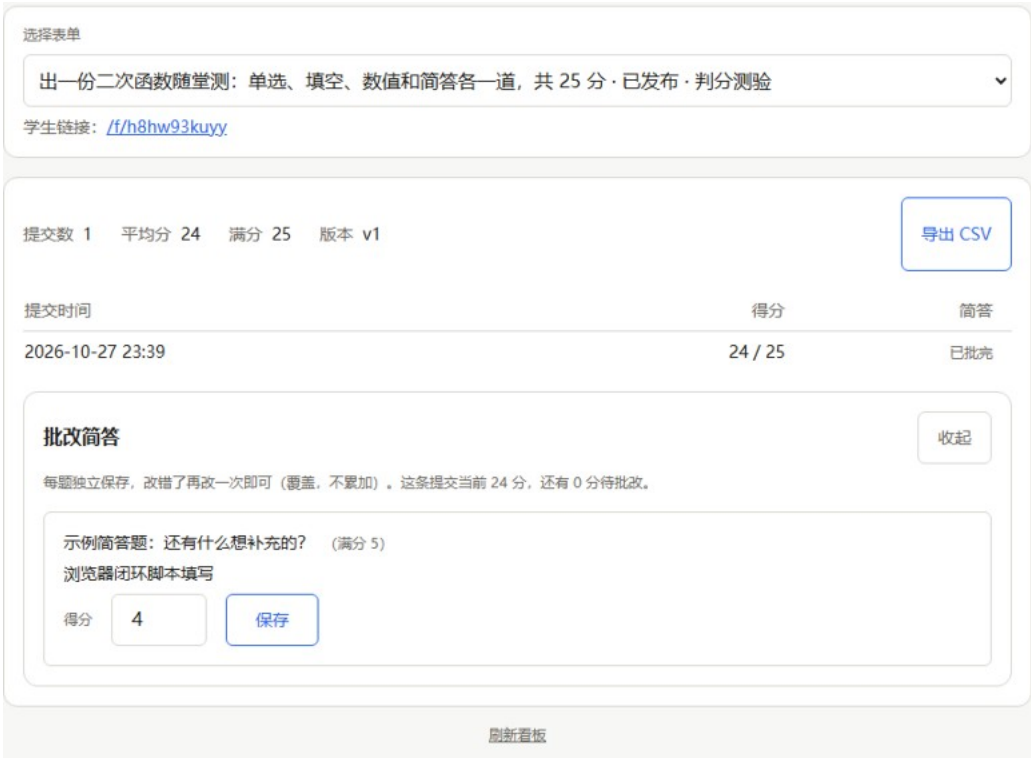



图 5-8　第 7 步的教师批改面板：逐题显示学生原文与满分（5 分），输入 4 分后总分行由 20 / 25 重算为 24 / 25，简答列从「待批 5 分」变为「已批完」

另有一张 03b-published-dashboard.png（发布后回到看板的中间态）在仓库里，为避免重复未嵌入。八张图连号同源，可对照 docs/evidence/README.md 的「最近一次运行」表核验时间戳。

## 6　项目之前是否发表过或获奖（对应要求 6）

| 项 | 实际情况 |
| --- | --- |
| 是否发表过 | 未发表。没有论文、没有公开文章、没有在任何应用商店或开源平台发布过成品 |
| 是否获奖 | 未获奖。本项目为首次参赛作品 |
| 是否首次提交 | 是。仓库的 83 次提交全部发生在 2026-10-26 至 10-27，为本次比赛新建，无历史版本对外发布 |
| 与其他赛事的关系 | 此前未以任何形式（含课程作业、毕业设计、其他赛事）提交过同一作品或其主要模块 |
| 预指导与省赛的关系 | 本版用于预指导；按组委会说明，预指导作品不作为省赛最终作品，省赛提交时以届时版本为准 |
| 第三方素材 | 未使用任何商用字体、图片、音频、视频素材；界面为自制，图标用系统字符与 CSS 绘制 |
| 演示数据 | 全部为种子脚本生成的虚构数据（2 份表单、30 条提交、虚构教师账号），不含任何真实师生信息 |

## 7　若在其他项目基础上优化，请说明优化部分（对应要求 7）

**声明：**本项目完全自主开发，未在任何其他项目、开源仓库、课程模板或商业脚手架的基础上优化。没有 fork 记录，没有克隆他人仓库后改名，也没有把别人的项目拆开重贴。

三条可核验的依据：

- 仓库第一次提交是 chore: init pnpm monorepo，此后 83 次提交按迭代 I0–I5 与省赛迭代推进，每条都能在 git log 里看到功能与测试成对出现；不存在一次性倒入大量代码的提交。
- 表单渲染、校验规则、SSE 协议、发布快照、判分逻辑全部是本仓库自写；被明确排除的框架（LangChain / LlamaIndex / Vercel AI SDK / formily / amis / SurveyJS / react-jsonschema-form）一个都没有进依赖树。
- 第三方依赖只有通用基础库，清单与用途如下（全部为 MIT / Apache-2.0 类宽松许可，未修改其源码）。

| 依赖 | 用途 | 许可 |
| --- | --- | --- |
| React 18 / React DOM | 界面渲染 | MIT |
| Vite 5 + @vitejs/plugin-react | 开发与构建 | MIT |
| Zod | 结构定义与运行时校验 | MIT |
| KaTeX | 公式渲染（trust:false） | MIT |
| better-sqlite3 | 本地数据库驱动 | MIT |

| | | |
|---|---|---|
| @node-rs/argon2 | 密码哈希 | MIT |
| vitest / oxlint / typescript | 测试、静态检查、类型检查 | MIT / Apache-2.0 |
| tailwindcss | 样式工具链（仅生成原子类，未用其组件库） | MIT |

**与 AI 协同产出的边界（这一条按实写）**：代码由本人与 AI 助手协同产出，AI 负责按契约实现与扩用例，本人负责架构约束（AGENTS.md）、协议冻结、验收与提交。因此本作品既不是「复制他人项目」，也不是「AI 一键生成」——每一次提交都能追到一条对话链（docs/prompt-log/P00–P04），且每条链都记了被否决的 AI 建议。评审若要求核实，按附录 B 的命令与目录即可。

最后说明本文档自身的变化：上一稿《参赛说明》按技术专题组织（10 页），本稿按官方 7 项重排并新增第 3 章（AI 测试）与第 5 章（截图），技术内容不删只挪，避免与《技术文档》重复描述同一条链。这是文档的优化，不构成项目的继承关系。

## 附录 A　已知缺口：现在做不到的，写清楚

这一节的作用是「评审怀疑某功能没做时先看这里」。下列 10 条都不是计划，是当前版本的真实状态；每条写明影响范围与触发条件，避免读者把它当成「以后会有」。

| # | 缺口 | 影响 / 触发条件 |
|---|---|---|
| 1 | 不做 Patch：改表单只能整份重发 | 教师想改一道题也要重新生成或整份保存；旧答案不与新版本合并 |
| 2 | 版本冲突只有 HTTP 级证据（VC2），没有浏览器级点击证据 | 界面侧冲突分支有单测，但缺一次真实点击；需等 Patch 上线才能补 |
| 3 | （已修复）简答字段没有分值 → R-01/R-02（c5c9b88 / 2c23c5e / 7bf0dbe） | 修前：需求写「含 N 道简答、每题 5 分、共 M 分」时总分凑不出来，30 条需求里 15 条无解，整份达标率被压到 42.9%（去掉这组 92.3%）。修法：short 可选带 score、新增 pendingScore、prompt 升 v2 重录回放、教师可人工批改；修后尚未重跑 eval |
| 4 | 澄清层未实现：缺槽位不追问 | 「帮我出一份英语卷子」「做个问卷」直接开生成，缺的题型与题量由模型自己猜；两条探针实测 0/2 |
| 5 | 达标率只测结构、不测题目质量 | 能算出题量/题型/知识点对不对，算不出难度是否合适、表述是否清楚、有没有歧义；后者要人工评分表 |
| 6 | 三条回放录自本机 OpenAI 兼容 stub | meta.json 的 upstream 为 local-stub；本轮已具备可用 Key（live 评测 28 条真跑过），但重录会改 fixture 内容并需重跑 VC1–VC4 与浏览器闭环，未在本轮做 |
| 7 | 只在 Windows + Chrome 156 验证 | 换浏览器或系统需重跑闭环脚本，否则截图证据视为过期 |
| 8 | 限流是进程内计数，不是 IP 级分布式限流 | 单机演示够用；多实例部署会失效 |
| 9 | CSV 未加 BOM | Excel 直接双击打开中文可能乱码，需另存为 UTF-8 或从数据导入 |
| 10 | 没有跨浏览器与移动端真机矩阵 | 手机截图来自 Chrome 的 390×844 视口模拟，不是真机 |

# 附录 B　复现清单与证据索引

五条命令覆盖「能不能跑」与「能不能对上」两件事，按顺序执行即可，不需要 API Key：

```
pnpm install
pnpm typecheck                          # 4 个包，0 错
npx vitest run                          # 54 文件 / 616 用例
node scripts/verify.mjs                 # VC1–VC4，4/4
node scripts/browser-closed-loop.mjs    # 6 步 8 图（需 Chrome，找不到 exit 2）
pnpm eval --mode replay                 # 不用 Key（只复核 3 条既有录像）
```

期望输出（verify.mjs）：

```
[verify] VC1 发布快照：改草稿不影响已发布版本的收集页 … 通过
[verify] VC2 判分与版本冲突：得分正确 / 旧版提交 409 … 通过
[verify] VC3 学生端零泄漏：响应体不含答案类键 … 通过
[verify] VC4 生成→发布→提交→看板：SSE 组装、得分对账、CSV 表头 … 通过
[verify] 全部通过（4/4）
```

| 证据 | 位置 | 能证明什么 |
| --- | --- | --- |
| 闭环截图 9 张 | docs/evidence/*.png（连号，同一次运行） | 界面真的能用：七步点得通，含教师批改，不是只有接口 |
| 截图与版本对应 | docs/evidence/README.md 的「最近一次运行」表 | 截图属于哪次运行、哪个 commit、什么浏览器 |
| HTTP 语义证据 | scripts/verify.mjs（VC1–VC4） | 快照隔离、409 冲突、零泄漏、数据对账 |
| 回放录像 3 组 | fixtures/replays/*.ndjson + *.meta.json | 无 Key 可重放真实时序；meta 记录模型与用量 |
| Prompt 链 5 条 | docs/prompt-log/P00–P04（核心三条 P01/P02/P04） | 每条链含提问、AI 建议（含被否决项）、修 bug 过程、commit |
| 架构约束 | AGENTS.md（模块边界、协议冻结、提交纪律） | AI 生成的代码为什么没有长歪 |
| 测试与类型 | 54 个 *.test.ts、4 个 tsconfig、oxlint 配置 | 616 用例、0 类型错、0 告警 |

本文档由 docs/deliverables/build_intro.py 生成（python-docx），改字改脚本重跑，不手改 docx，以保证文中引用的数字与仓库状态可复现。

# 附录 C　四种模式怎么跑（评委自带 Key 时）

模式由服务端的环境变量 LLM_MODE 决定，前端只是消费方——所以换成评委自己的 Key 不需要改一行代码、不需要重新构建前端。启动后 GET /healthz 会直接回当前模式，一眼可辨，不用猜：

```
curl -s http://127.0.0.1:8787/healthz
{"ok":true,...,"llmMode":"replay","needsApiKey":false}
```

| 模式 | 联网 | Key | 写盘 | 拿来干什么 | 耗时量级 |
|---|---|---|---|---|---|
| replay（默认） | 否 | 不需要 | 只读 fixtures/replays/ | 演示、评审复现、录视频 | instant 下 < 1 秒 |
| mock | 否 | 不需要 | 不落盘 | 单测、确定性截图（内置一条写坏再修复的题） | 即时 |
| live | 是 | 必需 | 不落盘 | 评委用真 Key 看真实模型输出 | 10–60 秒（受上游与超时约束） |
| record | 是 | 必需 | 写 <hash>.ndjson + .meta.json | 把一次真实调用录成回放，之后零 Key 可重放 | 同 live |

四条命令（Windows 的 bash / Git Bash；PowerShell 把前缀换成 $env:LLM_MODE="live"）。四个端口故意错开，方便对着开、来回切：

## C.1　replay：不需要 Key，默认就是它

```
PORT=8787 LLM_MODE=replay node --experimental-strip-types server/src/main.ts
# 期望启动日志：llm mode=replay（不打印 Key 相关提示）
# /healthz -> "llmMode":"replay","needsApiKey":false
```

三条预置需求（初二数学 / 高一英语 / 高二生物）能完整重放；换个说法就是未命中，而 replay 不会伪造结果——下面是实测的报文（不是示意图）：

```
# 用一条录像里没有的需求
curl -s -N -X POST http://127.0.0.1:8787/api/generate \
  -H 'content-type: application/json' \
  -d '{"requirement":"不在录像里的需求"}'
event: error
data: {"type":"error","seq":6,"code":"llm_config",
       "message":"回放未命中：本机没有这条需求的录制文件。replay 不伪造结果……",
       "retryable":false}
```

## C.2　mock：不联网、不落盘，用来演示与截图

```
PORT=8788 LLM_MODE=mock node --experimental-strip-types server/src/main.ts
# 期望：任何需求都吐同一份确定性表单（6 个节点、20 分），其中 1 条故意写坏、被修复环改对
# 时间线上能看到「q_repair_demo（第 3 项）已修复」+ 定向修复 1 轮
```

第 5 章那七张截图的生成步骤就是 mock——只有它能让「同一份需求每次得到同一份卷子」，截图才可复现。

## C.3 live：评委填自己的 Key，真调上游

```
PORT=8789 LLM_MODE=live \
  LLM_API_KEY=sk-评委自己的 key \
  LLM_BASE_URL=https://api.deepseek.com/v1 \
  LLM_CHAT_MODEL=deepseek-chat \
  node --experimental-strip-types server/src/main.ts
# 期望：/healthz -> "llmMode":"live","needsApiKey":false
# 期望：生成时中栏逐字段上屏，右栏时间线出现真实 usage（prompt / completion tokens）
```

没有 Key 就跑 live 会在启动期直接崩（实测输出），不会拖到第一次生成才报错：

```
$ PORT=8799 LLM_MODE=live node --experimental-strip-types server/src/main.ts
LlmError: live/record 模式需要 LLM_API_KEY
  code: 'llm_config',
  detail: 'LLM_API_KEY is empty; replay/mock 不需要 Key'
```

Base URL 是 OpenAI 兼容协议，换模型服务商只改 LLM_BASE_URL 与 LLM_CHAT_MODEL 两项；超时 LLM_TIMEOUT_MS（默认 60000）、单次上限 LLM_MAX_TOKENS（默认 4096）、温度 LLM_TEMPERATURE（默认 0，生成链路固定贪心）；生成接口另有 RATE_GENERATE_PER_MIN（默认 10）的限流。

## C.4 record：把一次真实调用录成回放，之后零 Key 可重放

```
PORT=8790 LLM_MODE=record \
  LLM_API_KEY=sk-评委自己的 key \
  node --experimental-strip-types server/src/main.ts
# 期望：生成结束后 fixtures/replays/ 多出一对文件
#   <replayKey>.ndjson     上游 chunk 的真实时序（{d, dt}）
#   <replayKey>.meta.json 模型、prompt 版本、chunk 数、总耗时、usage
```

两条纪律写死在代码里，评委会碰到：①只在正常结束时落盘，中途断流不写半截文件（半截 fixture 会被读侧判成损坏，比没有更糟）；②回放键由「需求 + 模型 + prompt 版本 + schema 版本」哈希而成，同一需求重录会覆盖同名文件。当前仓库里的三条录像，meta 里记的是 local-stub 上游与 deepseek-chat，也就是说它们来自联调桩，不是真实 DeepSeek 输出——这一点在附录 A 已列，评委用 record 重录即可换成真货。

## C.5 四个坑（都是真实踩过的）

- 服务端不读 .env：cp .env.example .env 不会生效，必须用 --env-file=.env 或把变量写在命令前缀上（仓库里没有 dotenv）。
- 换端口要同步改 APP_ORIGIN，否则 CORS + CSRF 来源校验直接 403；浏览器也用 127.0.0.1，别用 localhost。
- LLM_REASONING_MODEL 只出现在 .env.example 里、代码尚未读取——别把它当开关用（附录 A 已列）。

- Key 只在服务端，前端产物里没有；.env 与 .env.* 已 gitignore，最稳是放仓库外再用 --env-file 指过去。

一条命令自证模式确实切了：curl -s http://127.0.0.1:8788/healthz 只看 llmMode 字段；界面顶栏同时显示当前数据源，页面里的人不会误以为真模型在跑。

## C.6 按你想验的东西选一条

| 你想验什么 | 怎么做 | 期望看到 |
| --- | --- | --- |
| 只看界面，不配任何 Key | LLM_MODE=replay + pnpm dev:web，点预置需求 | 中栏逐字段上屏、右栏时间线推进、发布后才出现学生短链 |
| 真模型能不能写卷子 | LLM_MODE=live + 自己的 Key | 时间线出现真实 usage（prompt / completion tokens），题目内容随需求变 |
| 换模型或换服务商 | 改 LLM_BASE_URL 与 LLM_CHAT_MODEL 两项 | 启动日志与 /healthz 的 llmMode 变 live，生成照常 |
| 留一份自己的录像给评审 | LLM_MODE=record 跑一次后改回 replay | fixtures/replays/ 多一对 ndjson + meta，之后零 Key 可重放 |
| 确认现在到底是哪个模式 | curl /healthz 或看页面顶栏 | "llmMode" 与界面显示一致，不会含糊 |
| 核对判分与数据 | 生成→发布→作答→提交后看 /dashboard | 提交行得分与 CSV 表头一致（本次闭环 20 / 25，另有 5 分待批改） |

一句话：评委不需要动代码，也不需要任何 Key 就能看完整条链；想验证「真模型也行」，四条命令里的第三条就够。